Spam detection

Francesco Bellezza

Scopo

Cercare di costruire un modello che riesca a riconoscere quali sms sono spam: https://storm.cis.fordham.edu/~qweiss/data-mining/datasets.html

Software di utilizzo: Weka





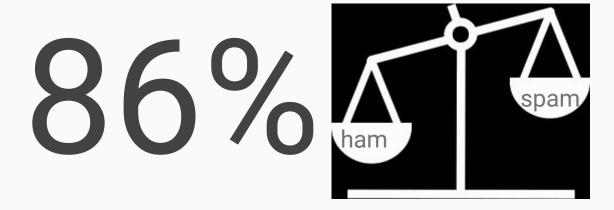
Preprocessing

I dati non sono bilanciati all'interno delle classi: quindi è necessario effettuare un bilanciamento! Sono presenti più sms non spam.



Inoltre, bisognerà effettuare la trasformazione dei vari sms in array di parole.





Rappresenta il numero di sms non spam che sono presenti nel dataset...
Rischio overfitting rispetto ai dati che abbiamo!

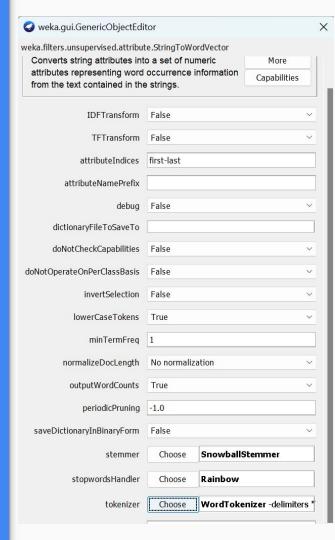
Subsample

Per evitare il problema di overfitting, decidiamo di generare un sottocampione in modo tale che le classi siano bilanciate.



StringToWordVect or

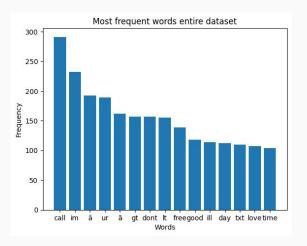
Abbiamo trasformato i testi dei vari sms in bag of words.

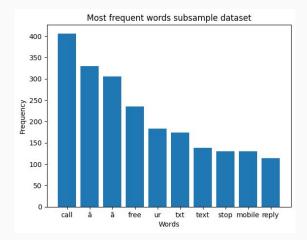


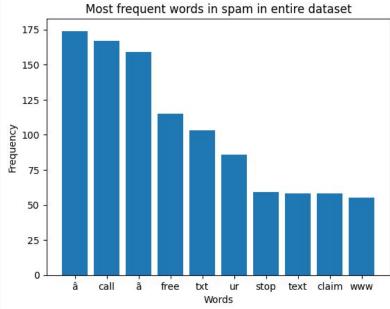
No.	1: Class Nominal	2: aah Numeric	3: aaniye Numeric	4: aathi Numeric	5: abel Numeric
1	ham	0.0	0.0	0.0	0.0
2	ham	0.0	0.0	0.0	0.0
3	ham	0.0	0.0	0.0	0.0
4	ham	0.0	0.0	0.0	0.0
5	ham	0.0	0.0	0.0	0.0
6	ham	0.0	0.0	0.0	0.0
7	ham	0.0	0.0	0.0	0.0
8	ham	0.0	0.0	0.0	0.0
9	ham	0.0	0.0	0.0	0.0
10	ham	0.0	0.0	0.0	0.0
11	ham	0.0	0.0	0.0	0.0

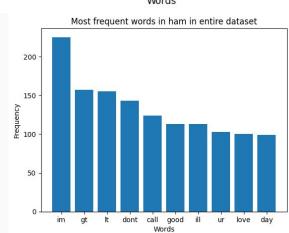
Frequenza delle parole

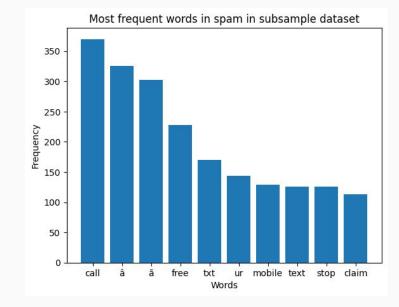
- Qui vengono riportate le parole più frequenti trovate nei vari sms.
- Facciamo vedere le differenze tra: le frequenze del dataset prima e dopo il sottocampionamento.

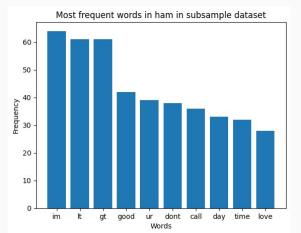






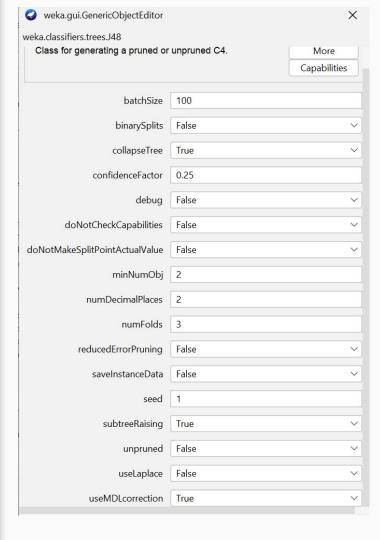






J48

Abbiamo utilizzato J48
 per costruire un albero
 di decisione per predire
 in base al contenuto se
 il messaggio è spam o
 meno.



Supplied test set		Set
Cross-validation	Folds	5
Percentage split	%	66

Risultati J48

```
Correctly Classified Instances
                                     1352
                                                        90.4953 %
                                                         9.5047 %
Incorrectly Classified Instances
                                      142
Kappa statistic
                                        0.8099
Mean absolute error
                                        0.1497
Root mean squared error
                                        0.2873
                                       29.9392 %
Relative absolute error
                                       57.4612 %
Root relative squared error
Total Number of Instances
                                     1494
=== Detailed Accuracy By Class ===
                TP Rate FP Rate Precision Recall
                                                      F-Measure MCC
                                                                          ROC Area PRC Area Class
                0,926
                         0,116
                                  0,888
                                             0,926
                                                      0,907
                                                                 0,811
                                                                          0,924
                                                                                    0,875
                                                                                              ham
                0.884
                         0,074
                                  0,923
                                             0.884
                                                      0,903
                                                                 0.811
                                                                          0.924
                                                                                    0,937
                                                                                              spam
Weighted Avg.
                0,905
                         0,095
                                  0,906
                                             0,905
                                                      0,905
                                                                 0,811
                                                                          0,924
                                                                                    0,906
=== Confusion Matrix ===
          <-- classified as
 692 55 | a = ham
 87 660 | b = spam
```

91.5663 % 8.4337 % con pruning

→ senza pruning

```
54.1451 %
Root relative squared error
Total Number of Instances
=== Detailed Accuracy By Class ===
               TP Rate FP Rate Precision Recall
                                                 F-Measure MCC
                                           0,963
                                                             0,835
                                                                     0,936
                                                                              0,895
                                          0,869
                                                  0,912
                                                             0,835
                                                                     0,936
                                                                              0,950
Weighted Avg.
              0,916
                                                 0,915
                                                             0,835
                                                                              0,923
=== Confusion Matrix ===
  a b <-- classified as
 719 28 | a = ham
  98 649 | b = spam
```

126

0.8313

0.1354

27.0755 %

Correctly Classified Instances

Kappa statistic

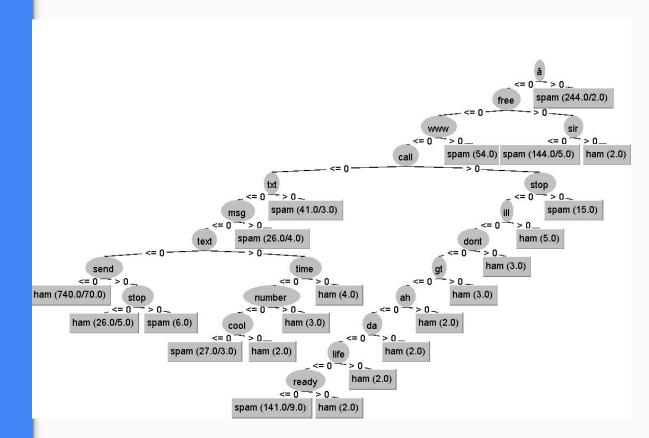
Mean absolute error

Root mean squared error Relative absolute error

Incorrectly Classified Instances

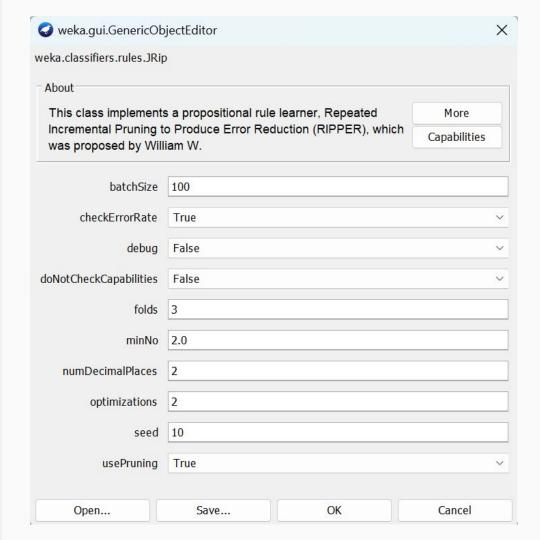
Albero di decisione

 Riportiamo qua a destra l'albero di decisione generato (è stato effettuato il pruning)



Rules Classifier JRIP

 Proviamo adesso ad utilizzare l'approccio con JRIP



Regole JRIP

- A fianco le regole generate dall'algoritmo
- Così come nel modello di classificazione JRIP, anche qui notiamo come alcune parole vengono considerate fonte di probabile messaggio di spam...

```
(call \leq 0) and (txt \leq 0) and (\hat{a} \leq 0) and (free \leq 0) and (www \leq
0) and (text <= 0) and (send <= 0) and (reply <= 0) and (service <=
0) and (http \leq 0) and (ringtone \leq 0) and (chat \leq 0) and (im \geq 1)
=> Class=ham (53.0/0.0)
(call \leq 0) and (txt \leq 0) and (text \leq 0) and (send \leq 0) and (reply
\neq 0) and (uk \neq 0) and (â \neq 0) and (http \neq 0) and (service \neq 0)
and (sms \leq 0) and (chat \leq 0) and (ringtone \leq 0) and (free \leq 0)
=> Class=ham (646.0/38.0)
(\hat{a} \le 0) and (\text{send} \ge 1) and (\text{stop} \le 0) and (\text{row} \le 0) and
(pounds \leq 0) and (mobile \leq 0) and (eve \leq 0) and (auction \leq 0)
=> Class=ham (28.0/4.0)
(\tilde{a} \le 0) and (ill \ge 1) = 0 Class=ham (9.0/1.0)
(\tilde{a} \le 0) and (gt \ge 1) = 0 Class=ham (4.0/0.0)
=> Class=spam (754.0/50.0)
```

Risultati JRIP

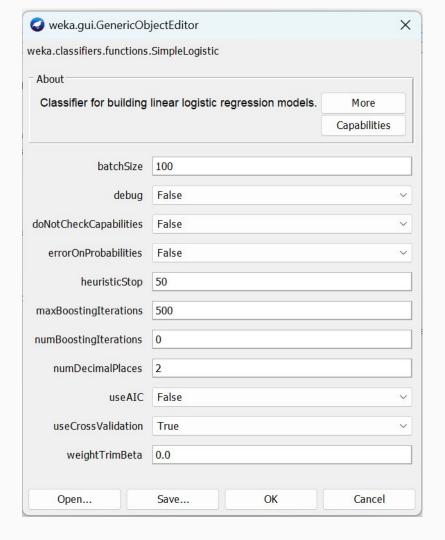
```
Correctly Classified Instances
                                    1358
                                                       90.8969 %
Incorrectly Classified Instances
                                     136
                                                        9.1031 %
Kappa statistic
                                       0.8179
Mean absolute error
                                       0.1385
                                       0.2873
Root mean squared error
                                      27.7026 %
Relative absolute error
Root relative squared error
                                      57.45 %
Total Number of Instances
                                    1494
=== Detailed Accuracy By Class ===
                TP Rate FP Rate Precision Recall
                                                     F-Measure MCC
                                                                         ROC Area PRC Area
                                                                                           Class
                0,917
                                                     0.910
                                                                                  0.892
                        0,099
                                 0,903
                                            0.917
                                                                0,818
                                                                        0.919
                                                                                            ham
                0,901
                        0,083
                                 0,916
                                            0,901
                                                     0,908
                                                               0,818
                                                                        0,919
                                                                                  0,909
                                                                                            spam
Weighted Avg.
                0.909
                        0.091
                                 0.909
                                            0.909
                                                    0,909
                                                               0,818
                                                                        0.919
                                                                                  0,900
=== Confusion Matrix ===
```

<-- classified as

685 62 | a = ham 74 673 | b = spam - Raggiungiamo una accuracy del 90.89%

LogitBoost

 Proviamo adesso ad utilizzare l'approccio usando SimpleLogistic, che sfrutta il boosting di LogitBoost, il quale utilizza come "base learners" delle regressioni.



Logistic regression con LogitBoost (Weka SimpleLogistic)

- L'algoritmo utilizza dei pesi.
- Il peso di grandezzamassima si ha quandop(x) = p(1-x)

LogitBoost (J classes)

- 1. Start with weights $w_{ij} = 1/n$, i = 1, ..., n, j = 1, ..., J, $F_j(x) = 0$ and $p_j(x) = 1/J \ \forall j$
- 2. Repeat for $m = 1, \ldots, M$:
 - (a) Repeat for $j = 1, \ldots, J$:
 - i. Compute working responses and weights in the jth class

$$z_{ij} = rac{y_{ij}^* - p_j(x_i)}{p_j(x_i)(1 - p_j(x_i))}$$

$$w_{ij} = p_j(x_i)(1 - p_j(x_i))$$

ii. Fit the function $f_{mj}(x)$ by a weighted least-squares regression of z_{ij} to x_i with weights w_{ij}

(b) Set
$$f_{mj}(x) \leftarrow \frac{J-1}{J} (f_{mj}(x) - \frac{1}{J} \sum_{k=1}^{J} f_{mk}(x)), \quad F_j(x) \leftarrow F_j(x) + f_{mj}(x)$$

(c) Update
$$p_j(x) = \frac{e^{F_j(x)}}{\sum_{k=1}^{J} e^{F_k(x)}}$$

3. Output the classifier argmax $F_j(x)$

Risultati LogitBoost

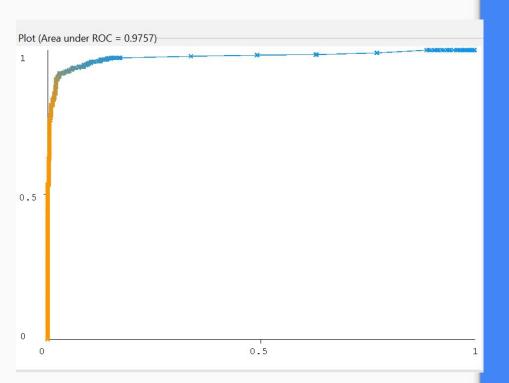
Time taken to build model: 19.89 seconds

70 677 | b = spam

```
=== Stratified cross-validation ===
=== Summary ===
Correctly Classified Instances
                                   1405
                                                      94.0428 %
                                                      5.9572 %
Incorrectly Classified Instances
                                      0.8809
Kappa statistic
Mean absolute error
                                      0.0978
                                      0.2185
Root mean squared error
Relative absolute error
                                     19 5617 %
Root relative squared error
                                     43.701 %
Total Number of Instances
                                   1494
=== Detailed Accuracy By Class ===
                TP Rate FP Rate Precision Recall F-Measure MCC
                                                                      ROC Area PRC Area Class
               0,975
                      0.094
                               0,912
                                           0,975
                                                   0.942
                                                              0.883
                                                                      0.976
                                                                               0.962
                                                                                         ham
                0.906
                        0.025
                                0.973
                                           0.906
                                                   0.938
                                                             0.883
                                                                      0.976
                                                                               0.981
                                                                                         spam
Weighted Avg.
               0.940
                       0.060
                                0.942
                                           0.940
                                                  0.940
                                                             0.883
                                                                      0.976
                                                                               0.972
=== Confusion Matrix ===
  a b <-- classified as
 728 19 | a = ham
```

 Raggiungiamo una accuracy ancora più elevata, del 94%!

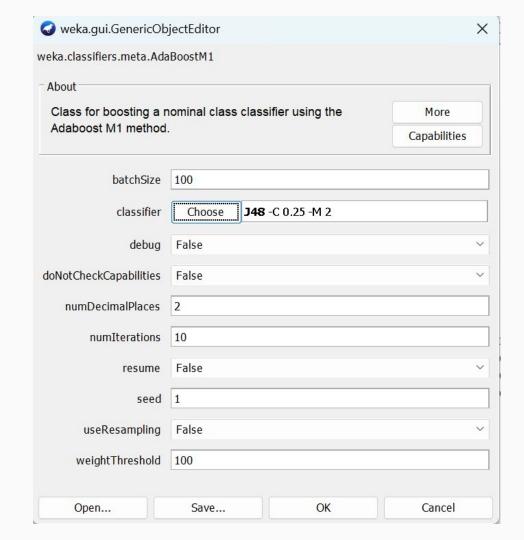
ROC LogitBoost



- L'area sotto la curva ROC è vicina ad 1!

AdaboostM1

- Usiamo l'algoritmo AdaboostM1.
- Come classificatore utilizziamo il J48



Risultati Adaboost

```
Correctly Classified Instances
                                      1399
                                                         93.6412 %
Incorrectly Classified Instances
                                                         6.3588 %
Kappa statistic
                                         0.8728
                                         0.062
Mean absolute error
Root mean squared error
                                         0.2413
Relative absolute error
                                        12.4005 %
Root relative squared error
                                        48.2558 %
Total Number of Instances
                                      1494
```

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0,949	0,076	0,926	0,949	0,937	0,873	0,972	0,954	ham
	0,924	0,051	0,948	0,924	0,936	0,873	0,972	0,979	spam
Weighted Avg.	0,936	0,064	0,937	0,936	0,936	0,873	0,972	0,966	

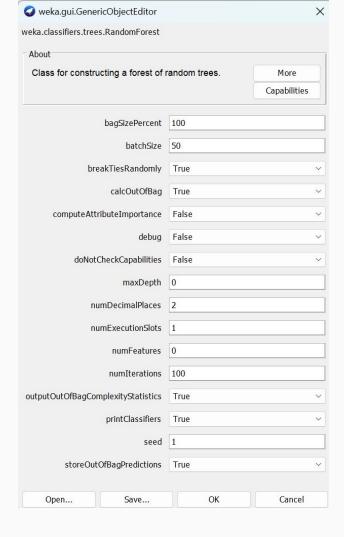
=== Confusion Matrix ===

```
a b <-- classified as
709 38 | a = ham
57 690 | b = spam
```

- Raggiungiamo una accuracy del 93.64%

Random Forest

- Infine proviamo ad utilizzare le random forest.
- Per valutare l'errore sfruttiamo le previsioni out of bag.



Risultati Random Forest

```
*** Out-of-bag estimates ***
Correctly Classified Instances
                                      1443
                                                         96 5863 %
Incorrectly Classified Instances
                                                          3.4137 %
Kappa statistic
                                         0.9317
K&B Relative Info Score
                                        82.4146 %
K&B Information Score
                                      1231.2736 bits
                                                          0.8241 bits/instance
Class complexity | order 0
                                      1494
                                                bits
                                                                 bits/instance
Class complexity | scheme
                                      3502.7266 bits
                                                        2.3445 bits/instance
Complexity improvement
                                                         -1.3445 bits/instance
                           (Sf)
                                     -2008.7266 bits
Mean absolute error
                                         0.1002
Root mean squared error
                                         0.1878
Relative absolute error
                                        20.0387 %
Root relative squared error
                                        37.5629 %
Total Number of Instances
                                      1494
```

=== Summary ===			
Correctly Classified Instances	1494	100	8
Incorrectly Classified Instances	0	0	8
Kappa statistic	1		
Mean absolute error	0.0371		
Root mean squared error	0.0709		
Relative absolute error	7.4257 %		
Root relative squared error	14.1702 %		
Total Number of Instances	1494		

- Raggiungiamo una accuracy del 96.58%
- In fase di training otteniamo il 100% di accuracy

Considerazioni Finali

- Nel nostro caso ci interessa una accuratezza più elevata e allo stesso tempo un numero di falsi positivi basso (bisognerebbe evitare che un sms importante venga classificato erroneamente come spam...)
- Per le configurazioni provate,
 l'algoritmo RandomForest di Weka performa meglio.

	Accuracy	FP
J48 (unpruned)	91.56%	28
LogitBoost	94.04%	19
JRip	90.89%	62
Adaboost M1	93.64%	38
Random Forest	96.58%	

Appendice: MultinomialNB

- Per curiosità abbiamo usato una MultinomialNB di scikit-learn.
- Tale funzione utilizza un Naive Bayes con la correzione di Laplace (se α = 1)
- Riusciamo con k-fold = 5 ad avere un accuracy del 95%! Inoltre Naive Bayes come algoritmo è particolarmente veloce e molto utilizzato anche per questo nella spam detection.

```
from sklearn.model_selection import cross_val_score, train_test_split
from sklearn.naive_bayes import MultinomialNB

X = dataframe_sub.drop("Class",axis="columns")
y = dataframe_sub["Class"].apply(lambda x: int(x == "spam"))

#alpha = 1 -> Laplace
mnb = MultinomialNB(alpha=1)
scores = cross_val_score(mnb, X, y, cv=5)
print("%0.3f accuracy and standard error %0.3f" % (scores.mean(), scores.std()))
```

0.952 accuracy and standard error 0.010

Bibliografia

- https://storm.cis.fordham.
 edu/~gweiss/data-mining/
 datasets.html
- Machine Learning, 59, 161–205, 2005 2005
 Springer Science + Business Media, Inc.
 Manufactured in The Netherlands. Logistic
 Model Trees* NIELS LANDWEHR
 landwehr@informatik.uni-freiburg.de Institute
 for Computer Science, University of Freiburg,
 Freiburg, Germany MARK HALL
 mhall@cs.waikato.ac.nz EIBE FRANK
 eibe@cs.waikato.ac.nz Department of
 Computer Science, University of Waikato,
 Hamilton, New Zealand
- Experiments with a New Boosting Algorithm, Yoav Freund Robert E. Schapire
- https://oneapi-src.qithub.io/oneDAL/daal/alqor thms/boosting/logitboost.html